

Projeto 1: Regressão com MLP e Estudo de Ablação

Disciplina: Introdução às Redes Neurais Artificiais

Autor(es): Gustavo Aumiller Tarijon (RA: 163790)

Repositório / Código Reprodutível: <https://github.com/GustavoAumiller/redes-neurais-projeto1>

1 Configuração Experimental e Reprodutibilidade

1.1 Pré-processamento e Partição dos Dados

O conjunto `dataset_projeto1.csv` contém 300 pares (x, y) com uma única entrada $x \in [0, 10]$. A partição foi feita com `train_test_split (random_state=42)` em duas etapas, resultando em **30 amostras de treino (10%), 30 de validação (10%) e 240 de teste (80%)**. Essa restrição intencional no volume de treino torna a tarefa suscetível ao sobreajuste, o que torna a investigação de hiperparâmetros e de regularização relevante.

O atributo x foi padronizado com `StandardScaler`, com média e desvio ajustados (*fit*) exclusivamente sobre as 30 amostras de treino; validação e teste receberam apenas *transform*, evitando vazamento de dados. O alvo y **não** foi escalonado, de modo que MSE, RMSE e MAE são reportados na escala original.

1.2 Definição e Otimização Empírica do Modelo Baseline (Vanilla)

O baseline é uma MLP básica treinada com SGD puro (`torch.optim.SGD`, `momentum = 0`), sem Adam e sem qualquer regularização (L1, L2 ou Dropout). **A maior parte dos experimentos deste relatório usa o orçamento de 500 épocas**; o de 5000 épocas foi executado apenas para o baseline, para o momentum e para execuções com todos os componentes ativos, e é usado aqui como destaque de como o comportamento se acentua com mais treino.

A busca foi empírica, em **uma única rodada de 500 épocas**, com oito configurações treinadas com a mesma semente e comparadas pelo menor MSE de validação (Tabela 2). Ao final do treino restauram-se os pesos da época de menor MSE de validação (seleção de *checkpoint*); não houve interrupção antecipada por paciência.

Tabela 1: Espaço amostrado e configuração final da MLP Baseline (Vanilla).

Hiperparâmetro	Valores explorados (busca)	Configuração usada na ablação
Topologia (camadas ocultas)	tanh: [16], [32], [64], [128,64], [16,8]; ReLU: [32], [64], [64,128]	Entrada $\rightarrow$ Densa(128) $\rightarrow$ Densa(64) $\rightarrow$ Saída(1) (8577 parâmetros)
Função de ativação	tanh, ReLU	ReLU (saída linear)
Otimizador / taxa η	SGD puro (momentum = 0), $\eta = 0.01$ (fixo)	SGD, $\eta = 0.01$
Tamanho do lote	16	32 (maior que as 30 amostras de treino: uma atualização por época)
Função de custo	MSE	<code>MSELoss</code>
Orçamento de épocas	500	500 (principal) e 5000 (destaque)
Critério de seleção	Menor MSE de validação (<i>checkpoint</i> da melhor época)	idem
Semente aleatória	Fixa, reiniciada antes de cada modelo	Seed = 42

Tabela 2: Erros de validação dos oito modelos candidatos a baseline (500 épocas, $\eta = 0.01$, lote 16), ordenados por MSE.


Topologia	Ativ.	Melhor época	MSE	RMSE	MAE	R^2
$1 \rightarrow 64 \rightarrow 128 \rightarrow 1$	ReLU	497	0.5314	0.7290	0.6041	0.1376
$1 \rightarrow 64 \rightarrow 1$	ReLU	493	0.5747	0.7581	0.6237	0.0672
$1 \rightarrow 32 \rightarrow 1$	ReLU	500	0.5799	0.7615	0.6253	0.0589
$1 \rightarrow 128 \rightarrow 64 \rightarrow 1$	tanh	497	0.5972	0.7728	0.6380	0.0309
$1 \rightarrow 16 \rightarrow 8 \rightarrow 1$	tanh	493	0.6035	0.7769	0.6292	0.0205
$1 \rightarrow 32 \rightarrow 1$	tanh	191	0.6072	0.7793	0.6310	0.0145
$1 \rightarrow 16 \rightarrow 1$	tanh	267	0.6124	0.7825	0.6366	0.0062
$1 \rightarrow 64 \rightarrow 1$	tanh	64	0.6134	0.7832	0.6385	0.0046

A melhor configuração da busca foi ReLU com camadas ocultas [64, 128] (MSE de validação 0.531), seguida por ReLU [64] (0.575) e ReLU [32] (0.580). Cinco dos oito modelos tiveram a melhor época a menos de 2% do fim do orçamento (493–500 de 500), ou seja, a rodada ainda não havia convergido, e a diferença entre o primeiro e o segundo colocado (0.043) foi obtida com uma única semente. A ablação foi feita com a arquitetura $1 \rightarrow 128 \rightarrow 64 \rightarrow 1$ com ReLU, que tem o mesmo número de parâmetros (8577) do vencedor da busca, mas com a ordem das camadas invertida: a variante [128, 64] com ReLU não foi avaliada na busca (só a com tanh, em 4º lugar, MSE 0.597). Com 500 épocas o baseline da ablação chega a MSE de treino ≈ 0.46 e de validação 0.571, ambos ainda em queda (Fig. 1a).


Reprodutibilidade. A busca do baseline está em `baseline.py` e o estudo de ablação em `hyperparametros.py`. Cada resultado reportado corresponde a uma execução com os valores de β , λ , p e número de épocas indicados nas tabelas; em cada modelo apenas um componente foi ativado por vez, e os demais ficaram desativados ($\beta = 0$, $\lambda = 0$, $p = 0$). Os componentes são somados à perda ($\lambda \sum |w|$ e $\lambda \sum w^2$, sobre todos os parâmetros, sem o fator $1/2n$ dos slides) ou aplicados na rede (Dropout após cada camada oculta).

2 Dinâmica de Treinamento e Convergência (Baseline vs. Modificados)


A evolução do MSE de treino e de validação foi registrada a cada época. A Figura 1 mostra o baseline e o momentum com 500 épocas (a, b) e com 5000 épocas (c, d), e a Figura 2 compara a validação de todos os modelos nos dois orçamentos: só o momentum (linha superior) e todos os componentes ativos, com $\lambda_{L1} = \lambda_{L2} = 0.1$, $p = 0.2$ e $\beta = 0.9$ (linha inferior). Todas as comparações usam a mesma arquitetura, a mesma semente e o mesmo lote.




(a) Baseline, 500 épocas.



(b) Momentum $\beta = 0.9$, 500 épocas.




(c) Baseline, 5000 épocas.




(d) Momentum $\beta = 0.9$, 5000 épocas.


Figura 1: MSE de treino e de validação (lote 32). Como o lote é maior que o conjunto de treino, o MSE de treino é o de uma única atualização por época.




(a) Só momentum, 500 épocas.



(b) Só momentum, 5000 épocas.



(c) Todos os componentes, 500 épocas.



(d) Todos os componentes, 5000 épocas.

Figura 2: MSE de validação: evolução de 500 para 5000 épocas. Em (a) e (b), L1, L2 e Dropout estavam desativados e coincidem com o baseline (a curva do baseline fica sob elas). Em (c) e (d): L1 e L2 com $\lambda = 0.1$, Dropout $p = 0.2$, momentum $\beta = 0.9$, cada um em um modelo separado.

Análise crítica da dinâmica de convergência:

- **Estabilidade do SGD.** Com $\eta = 0.01$ o baseline não divergiu. Como o lote (32) excede as

30 amostras de treino, cada época é uma atualização com o gradiente completo, e as curvas são suaves, sem ruído de mini-lote. Com 500 épocas a validação cai de ≈ 0.78 para ≈ 0.61 nas primeiras épocas e depois decresce quase linearmente até 0.571, sem convergir (melhor época 500; Fig. 1a). Com 5000 épocas continua caindo, até 0.396 (melhor época 4995; Fig. 1c): a convergência é lenta com essa taxa.

- **Sobreajuste.** Com 500 épocas não há sinal de sobreajuste: treino (≈ 0.46) e validação (0.571) caem juntos, tanto no baseline quanto no momentum (≈ 0.30 e 0.41). O sobreajuste aparece com o treino mais longo e, sobretudo, com momentum: com 5000 épocas o MSE de treino do momentum cai a ≈ 0.03 enquanto o de validação estaciona em torno de 0.25–0.30 (Fig. 1d). No baseline com 5000 épocas a distância entre treino (≈ 0.27) e validação (0.396) é de ≈ 0.13 , e o erro de teste (0.529) é pior que prever a média do treino (0.523; Tabela 4).
- **Aceleração com momentum.** Sim. Com 500 épocas o momentum $\beta = 0.9$ chega a 0.408 de MSE de validação, contra 0.571 do baseline (Fig. 2a), e o baseline só atinge esse nível por volta da época 4500 (Fig. 1c), cerca de nove vezes mais épocas. O custo é a instabilidade: oscilações nas primeiras ≈ 50 épocas (a validação chega a ≈ 0.81) e, com 5000 épocas, picos de perda entre as épocas ≈ 880 e ≈ 2700 (o de validação chega a 2.1 na época ≈ 1550), coerentes com um passo efetivo maior ($\eta/(1 - \beta) = 0.1$).
- **Todos os componentes, de 500 para 5000 épocas (Fig. 2c e d).** Com $\lambda = 0.1$, L1 e L2 travam cedo: a validação de L1 sobe até ≈ 0.63 por volta da época 85 e estabiliza em ≈ 0.62 , e a de L2 fica em ≈ 0.60 , e nenhuma muda entre 500 e 5000 épocas (as melhores épocas, 23 e 360, ocorrem antes de 500). O Dropout $p = 0.2$ acompanha o baseline com pequena defasagem em 500 épocas (0.586 contra 0.571) e continua descendo até 0.459 em 5000, ainda acima do baseline (0.396). O momentum se separa cedo dos demais e chega a 0.206 em 5000 épocas.

3 Estudo de Ablação e Desempenho no Conjunto de Teste

Para isolar o efeito de cada componente, a arquitetura (camadas, ativações, semente e inicialização) foi mantida idêntica à da Tabela 1, avaliando-se as variações individuais abaixo com 500 épocas (Tabela 3).

1. Baseline + Momentum: $\beta \in \{0.25, 0.5, 0.75, 0.9\}$.
2. Baseline + L2: $\lambda \in \{10^{-3}, 10^{-2}, 10^{-1}\}$.
3. Baseline + L1: $\lambda \in \{10^{-3}, 10^{-2}, 10^{-1}\}$.
4. Baseline + Dropout (após cada camada oculta): $p \in \{0.1, 0.2, 0.3, 0.5\}$.

Combinações de componentes (modelo combinado) não foram avaliadas. As métricas são do conjunto de teste (240 amostras, não usado para treino nem para seleção); $R^2 < 0$ indica desempenho pior que prever a média do treino. A coluna de épocas indica a época do melhor MSE de validação. Pelo MSE de validação, os melhores valores seriam $\beta = 0.9$, $\lambda = 10^{-3}$ (L1 e L2) e $p = 0.1$.

Tabela 3: Estudo de ablação no conjunto de teste (80% dos dados), orçamento de 500 épocas.

Modelo / Variação	MSE val.	MSE	RMSE	MAE	R^2	Melhor época
Baseline (SGD, $\eta=0.01$)	0.5711	0.5586	0.7474	0.6108	-0.1085	500
+ Momentum ($\beta=0.25$)	0.5542	0.5499	0.7415	0.6100	-0.0912	500
+ Momentum ($\beta=0.5$)	0.5225	0.5366	0.7326	0.6095	-0.0649	500
+ Momentum ($\beta=0.75$)	0.4711	0.5346	0.7312	0.6148	-0.0609	500
+ Momentum ($\beta=0.9$)	0.4080	0.5204	0.7214	0.6041	-0.0327	496
+ L2 ($\lambda=10^{-3}$)	0.5721	0.5588	0.7475	0.6106	-0.1089	498
+ L2 ($\lambda=10^{-2}$)	0.5797	0.5607	0.7488	0.6102	-0.1128	500
+ L2 ($\lambda=10^{-1}$)	0.6018	0.5321	0.7294	0.5929	-0.0559	360
+ L1 ($\lambda=10^{-3}$)	0.5750	0.5602	0.7484	0.6108	-0.1116	498
+ L1 ($\lambda=10^{-2}$)	0.5972	0.5501	0.7417	0.6024	-0.0916	500
+ L1 ($\lambda=10^{-1}$)	0.6112	0.5087	0.7132	0.5811	-0.0094	23
+ Dropout ($p=0.1$)	0.5775	0.5493	0.7411	0.6051	-0.0900	491
+ Dropout ($p=0.2$)	0.5858	0.5461	0.7390	0.6022	-0.0837	495
+ Dropout ($p=0.3$)	0.5891	0.5409	0.7354	0.5994	-0.0733	476
+ Dropout ($p=0.5$)	0.6033	0.5255	0.7249	0.5912	-0.0429	498
Referência: prever a média do treino	0.6300	0.5229	0.7231	0.5857	-0.0376	–

Destaque: de 500 para 5000 épocas. A Tabela 4 compara os dois orçamentos para a execução geral (L1 e L2 com $\lambda = 0.1$, $p = 0.2$, $\beta = 0.9$). As linhas de L1 e L2 são idênticas nos dois orçamentos porque a melhor época de validação (23 e 360) vem antes de 500. Uma execução adicional de 5000 épocas com $\lambda_{L1} = \lambda_{L2} = 10^{-3}$ deu MSE de teste 0.535 (L1) e 0.539 (L2), próximo do baseline (0.529).


Tabela 4: Comparação entre 500 e 5000 épocas (execução geral; MSE e R^2 de teste).

Modelo	500 épocas				5000 épocas			
	Época	MSE val.	MSE teste	R^2	Época	MSE val.	MSE teste	R^2
Baseline	500	0.5711	0.5586	-0.1085	4995	0.3961	0.5290	-0.0497
Momentum ($\beta=0.9$)	496	0.4080	0.5204	-0.0327	3209	0.2058	0.3051	0.3946
Dropout ($p=0.2$)	495	0.5858	0.5461	-0.0837	4999	0.4586	0.4880	0.0317
L2 ($\lambda=0.1$)	360	0.6018	0.5321	-0.0559	360	0.6018	0.5321	-0.0559
L1 ($\lambda=0.1$)	23	0.6112	0.5087	-0.0094	23	0.6112	0.5087	-0.0094


Efetividade comparada dos componentes. A Figura 3 mostra o gráfico de valor real $\times$ previsto no teste para os cinco modelos da execução geral com 500 épocas, e a Figura 4, com 5000 épocas. A Tabela 5 resume a diferença de MSE de teste em relação ao baseline do mesmo orçamento (negativo é melhor) e o que se vê nos gráficos.

Tabela 5: Efetividade de cada componente: variação do MSE de teste em relação ao baseline do mesmo orçamento e leitura dos gráficos real $\times$ previsto.


Componente	ΔMSE (500)	ΔMSE (5000)	Gráfico real $\times$ previsto
Momentum ($\beta=0.9$)	-0.038	-0.224	Único que amplia a faixa de predições já com 500 épocas e, com 5000, passa a acompanhar a diagonal; ainda subestima os extremos.
Dropout ($p=0.2$)	-0.013	-0.041	Parecido com o baseline com 500 épocas; com 5000 tem inclinação positiva, mas faixa de predições mais estreita que a do baseline.
L2 ($\lambda=0.1$)	-0.027	+0.003	Predições quase constantes ($\approx 0.4\text{--}0.9$), sem mudança entre 500 e 5000 épocas.
L1 ($\lambda=0.1$)	-0.050	-0.020	Predições quase constantes ($\approx 0.4\text{--}0.65$), sem mudança entre 500 e 5000 épocas; colapso mais forte que o de L2.




(a) Baseline.




(b) L1 ($\lambda = 0.1$).



(c) L2 ($\lambda = 0.1$).



(d) Dropout ($p = 0.2$).



(e) Momentum ($\beta = 0.9$).

Figura 3: Valor real $\times$ previsto no conjunto de teste (240 amostras), execução geral com **500 épocas**; a linha tracejada é $y = x$.




Figura 4: Valor real $\times$ previsto no conjunto de teste (240 amostras), execução geral com **5000 épocas**; a linha tracejada é $y = x$.

4 Discussão e Lições Aprendidas

- **SGD vanilla com poucos dados (10% de treino).** A rede tem 8577 parâmetros para 30 amostras de treino. Com 500 épocas o baseline tem $R^2 = -0.109$ no teste (MSE 0.559, cerca de 7% pior que o 0.523 de prever a média do treino) e, com 5000 épocas, $R^2 = -0.050$ (0.529), apesar de R^2 de validação de 0.073 e 0.357. A validação de 30 pontos não é representativa: sua variância (0.616) é maior que a do teste (0.504), e prever a média já dá MSE 0.630 na validação. Por isso a seleção por validação é pouco confiável neste problema. Com 500 épocas nenhuma técnica melhora a validação; no teste, os componentes fracos ($\lambda = 10^{-3}$, $\beta \leq 0.5$) variam o MSE em até cerca de 0.02, e os ganhos de L1, L2 e Dropout fortes vêm de aproximar o modelo de uma predição constante (L1 com $\lambda = 0.1$: 0.509 contra 0.559), não de melhor aprendizado da função; o momentum, ao contrário, melhora também a validação. Dentre as técnicas, o **momentum** é a mais efetiva (Tabela 5), e o Dropout é a única regularização com ganho no teste com 5000 épocas.
- **Ação específica dos componentes de ablação:**
 - *Momentum.* Mudou claramente a velocidade da curva (Fig. 2a). Com 500 épocas o MSE de validação melhora monotonicamente com β (0.571 $\rightarrow$ 0.554, 0.523, 0.471, 0.408), com ganho pequeno no teste (0.559 $\rightarrow$ 0.520); com 5000 épocas o ganho no teste é grande (0.529 $\rightarrow$ 0.305, $R^2 = 0.39$). Como o baseline ainda melhorava ao fim do orçamento (melhor época 4995), parte do ganho reflete velocidade de otimização, e não necessariamente um patamar melhor; não há execuções com orçamentos maiores para separar os dois efeitos.

- *L1 vs. L2.* Com $\lambda = 10^{-3}$ os dois praticamente não alteram o baseline (validação 0.575 e 0.572 com 500 épocas). Com o mesmo λ , L1 é mais agressiva: em 10^{-2} o MSE de validação é 0.597 (L1) contra 0.580 (L2), e em 0.1 a melhor época é a 23 (L1) contra a 360 (L2), com R^2 de validação de 0.008 e 0.023. Nos gráficos real $\times$ previsto ambos colapsam para predições quase constantes (Figs. 3 e 4), o que não muda com mais épocas. Não foi medida a esparsidade dos pesos; com uma única entrada, o uso de L1 para seleção de atributos também não se aplica.
 - *Dropout.* Com 500 épocas, aumentar p de 0.1 a 0.5 piora o MSE de validação (0.578 $\rightarrow$ 0.603) e melhora o de teste (0.549 $\rightarrow$ 0.526), padrão que se repete com 5000 épocas ($p = 0.2$: validação 0.459 contra 0.396 do baseline, teste 0.488 contra 0.529). Como validação e teste discordam, o sinal favorável ao Dropout deve ser lido com cautela. Com 500 épocas o gráfico real $\times$ previsto do Dropout é parecido com o do baseline (Fig. 3); com 5000 épocas ele passa a ter inclinação positiva, mas com faixa de predições mais estreita que a do baseline (Fig. 4).
 - *Outras análises.* A mudança de 500 para 5000 épocas acentua as diferenças: o baseline ($-0.109 \rightarrow -0.050$ de R^2) e o Dropout ($-0.084 \rightarrow 0.032$) melhoram pouco, o momentum passa de -0.033 a 0.395 , e L1 e L2 fortes não mudam (Tabela 4). Os valores varridos apenas com 500 épocas (Tabela 3) refletem em boa parte a velocidade de aprendizado, já que o baseline ainda não havia convergido.
- **Análise de resíduos e limitações.** Com 500 épocas (Fig. 3) o baseline prevê valores entre ≈ 0.15 e 1.4 sem relação visível com o valor real; L1 (≈ 0.4 – 0.65) e L2 (≈ 0.4 – 0.9) colapsam para uma faixa quase constante; o Dropout é semelhante ao baseline (≈ 0.2 – 1.2); e o momentum é o único com faixa ampla (≈ -0.3 a 2.3), mas com muitas superestimativas (valores reais entre ≈ 0.5 e 1.8 previstos em ≈ 2.0 – 2.3). Com 5000 épocas (Fig. 4) o baseline ganha inclinação e dispersão (≈ -0.3 a 2.3), o Dropout fica intermediário (≈ -0.15 a 1.8), L1 e L2 não mudam e o momentum forma uma nuvem alinhada à diagonal, inclusive na cauda inferior. Persiste em todos os modelos a subestimação dos maiores valores reais (≈ 1.9 e ≈ 2.65 , previstos entre 0.4 e 0.9) e, nos modelos com faixa de predições ampla (momentum e baseline com 5000 épocas), um grupo de superestimativas (y real entre ≈ 0.5 e 1.8 , previsto em ≈ 2 – 2.4). O alvo é ruidoso; uma estimativa exploratória da variância do ruído, pela diferença entre pontos vizinhos nos 300 pontos, dá um limite superior aproximado de 0.17 , bem abaixo dos MSE obtidos, o que sugere que o gargalo é a escassez de dados e de treino, e não o ruído irreduzível. O gráfico de resíduos $y - \hat{y}$ não foi produzido; a análise se baseia nos gráficos real $\times$ previsto.
 - **Limitações.** (i) Uma única semente (42), sem estimativa de variância; (ii) validação de 30 amostras, usada também para escolher a época; (iii) a busca do baseline foi de uma única rodada de 500 épocas, sem convergência, com espaço restrito, e a ordem das camadas usada na ablação ([128, 64]) difere da do vencedor da busca ([64, 128]); (iv) a busca usou lote 16 (duas atualizações por época) e a ablação usou lote 32 (uma atualização por época, gradiente completo); (v) as varreduras de β , λ e p foram feitas com 500 épocas, regime em que o baseline ainda não convergiu, e o orçamento de 5000 épocas só foi executado para o baseline, o momentum e as execuções com todos os componentes ativos; (vi) sem orçamentos maiores que 5000 épocas e sem modelo combinado.